

Notatki z Algorytmów i Struktur Danych

Jakub Kogut

18 marca 2025

Spis treści

1	Wstęp	2
1.1	Informacje	2
1.2	Ocenianie	2
2	Wykład 2025-03-03	2
2.1	Przykładowy Problem	2
2.2	Jak mierzyć złożoność algorytmów	2
2.3	Przykład algorytmu	3
2.4	Przykład działania Merge Sort	3
2.5	Złożoność Merge Sort	4
3	Wykład 2025-03-10	4
3.1	Notacja Asymptotyczna	4
3.2	Rekurencja	6
4	Wykład 2025-03-17	6
4.1	Drzewo rekursji	6
4.2	Metoda iteracyjna	7
4.3	Master Theorem	7
4.4	Metoda dziel i zwyciężaj (D&C)	9
4.4.1	Algorytm – Binary Search	9
4.4.2	Algorytm – potęgowanie liczby do naturalnej potęgi	10
4.4.3	Obliczenie n-tej liczby Fibonacciego	10
4.4.4	Mnożenie liczb	11
4.4.5	Mnożenie macierzy	12
4.4.6	Quick Sort	13
5	Ćwiczenia	14
5.1	Lista 2	14
5.1.1	zadanie 1	14
5.1.2	zadanie 2	15
5.1.3	zadanie 3	15
5.1.4	zadanie 4	16
5.1.5	zadanie 5	17
5.1.6	zadanie 6	18
5.1.7	zadanie 7	18

1 Wstęp

To będą notatki z przedmiotu Algorytmy i struktury danych na Politechnice Wrocławskiej na kierunku Informatyka Algorytmiczna rok 2025 semestr letni.

1.1 Informacje

Prowadzący Przedmiot: **Zbychu Gołębiewski**

- Należy kontaktować się przez maila: [mail](#)
- Konsultacje **216/D1**:
 - Wtorek 13:00-15:00
 - Środa 9:00-11:00
- Więcej info na stronie [przedmiotu](#)
- Literatura
 - Algorithms, Dasgupta, Papadimitriou, Vazirani
 - Algorithms, Sedgewick, Wayne (strona internetowa książki)
 - Algorithms Designs, Jon Kleinberg and Eva Tardos
 - Wprowadzenie do algorytmów, Cormen, Leiserson, Rivest, Stein
 - Sztuka programowania (wszystkie tomy), Donald E. Knuth

1.2 Ocenianie

Ocena z kursu składa się z:

- Oceny z egzaminu – E
- Oceny z ćwiczeń – C
- Oceny z laboratorium – L

Wszystkie oceny są z zakresu $[0, 100]$. Ocena końcowa jest wyliczana ze wzoru:

$$K = \frac{1}{2}E + \frac{1}{4}C + \frac{1}{4}L$$

2 Wykład 2025-03-03

2.1 Przykładowy Problem

Sortowanie:

- Input: n liczb $a_1, a_2, \dots, a_n, |A|$, gdzie $|A|$ to długość tablicy
- Output: permutacja a'_1, a'_2, \dots, a'_n taka, że $a'_1 \leq a'_2 \leq \dots \leq a'_n$

Najważniejsze w algorytmach jest to, żeby były POPRAWNE: edge case, ...

2.2 Jak mierzyć złożoność algorytmów

1. Worst Case Analysis $T(n) \leftarrow$ stosowane najczęściej
2. Average Case Analysis

- zakładamy pewnen rozkład prawdopodobieństwa na danych wejściowych
- T – zmienna losowa liczby operacji wykonanych przez algorytm

$$T(n) = \max\{\text{\#operacji dla danego wejścia}\}$$

- $E[T]$ – wartość oczekiwana $T \rightarrow$ średnia liczba operacji, to co nas interesuje

2.3 Przykład algorytmu

W tej sekcji mamy pokazany przykład jak pisać pseudo kod:

Algorithm 1 Merge Sort

```
1: procedure MERGESORT( $A, 1, n$ )
2:   if  $|A[1..n]| == 1$  then
3:     return  $A[1..n]$ 
4:   else
5:      $B = \text{MergeSort}(A, 1, \lfloor n/2 \rfloor)$ 
6:      $C = \text{MergeSort}(A, \lfloor n/2 \rfloor, n)$ 
7:     return Merge( $B, C$ )
8:   end if
9: end procedure
```

Algorithm 2 Merge

```
1: procedure MERGE( $X[1..k], Y[1..n]$ )
2:   if  $X = \emptyset$  then
3:     return  $Y$ 
4:   else if  $Y = \emptyset$  then
5:     return  $X$ 
6:   else if  $X[1] \leq Y[1]$  then
7:     return  $[X[1]] \times \text{Merge}(X[2..k], Y[1..n])$ 
8:   else
9:     return  $[Y[1]] \times \text{Merge}(X[1..k], Y[2..n])$ 
10:  end if
11: end procedure
```

2.4 Przykład działania Merge Sort

Example: Sorting the array $[10, 2, 5, 3, 7, 13, 1, 6]$ step by step

1. **Initial split:**

$$[10, 2, 5, 3, 7, 13, 1, 6] \longrightarrow [10, 2, 5, 3] \text{ and } [7, 13, 1, 6].$$

2. **Sort the left half** $[10, 2, 5, 3]$:

- (a) Split into $[10, 2]$ and $[5, 3]$.
- (b) MergeSort($[10, 2]$):
 - Split into $[10]$ and $[2]$.
 - Each is already sorted (single element).
 - Merge: $[2, 10]$.
- (c) MergeSort($[5, 3]$):
 - Split into $[5]$ and $[3]$.
 - Each is already sorted.
 - Merge: $[3, 5]$.
- (d) Merge $[2, 10]$ and $[3, 5]$ to get $[2, 3, 5, 10]$.

3. **Sort the right half** $[7, 13, 1, 6]$:

- (a) Split into $[7, 13]$ and $[1, 6]$.

(b) MergeSort([7, 13]):

- Split into [7] and [13].
- Each is already sorted.
- Merge: [7, 13].

(c) MergeSort([1, 6]):

- Split into [1] and [6].
- Each is already sorted.
- Merge: [1, 6].

(d) Merge [7, 13] and [1, 6] to get [1, 6, 7, 13].

4. **Final merge:** Merge the two sorted halves:

$$[2, 3, 5, 10] \quad \text{and} \quad [1, 6, 7, 13] \quad \longrightarrow \quad [1, 2, 3, 5, 6, 7, 10, 13].$$

Hence, after all the recursive splits and merges, the final sorted array is:

$$[1, 2, 3, 5, 6, 7, 10, 13].$$

2.5 Złożoność Merge Sort

- Złożoność czasowa

$$- T(n) = 2T(n/2) + \Theta(n)$$

$$- T(n) = \Theta(n \log n)$$

- Złożoność pamięciowa

$$- M(n) = n + M(n/2)$$

$$- M(n) = \Theta(n)$$

3 Wykład 2025-03-10

3.1 Notacja Asymptotyczna

Na wykładzie będziemy omawiali:

- Notację dużego O $O(n)$ //ograniczenie górne

– Definicja $O(n)$:

$$O(g(n)) = \{f(n) \mid \exists c > 0, \exists n_0 \in \mathbb{N}, \forall n \geq n_0, 0 \leq f(n) \leq c \cdot g(n)\}$$

– Uwaga!

Jeśli

$$\limsup_{n \rightarrow \infty} \frac{f(n)}{g(n)} < \infty$$

to

$$\limsup_{n \rightarrow \infty} \frac{f(n)}{g(n)} = \lim_{n \rightarrow \infty} \frac{f(n)}{g(n)}$$

– Przykład:

* $2n^2 = O(n^3)$ dla $n_0 = 2, c = 1$ Definicja jest spełniona

* $f(n) = n^3 + O(n^2)$ jest to jeden z sposobów użycia $O(n)$

$$\exists h(n) = O(n^2) \quad \text{takie, że} \quad f(n) = n^3 + h(n)$$

- Notację omega //ograniczenie dolne

– Definicja

$$\Omega(g(n)) = \{f(n) \mid \exists c > 0, \exists n_0 \in \mathbb{N}, \forall n \geq n_0, 0 \leq c \cdot g(n) \leq f(n)\}$$

– Przykład

$$* n^3 = \Omega(2n^2)$$

$$* n = \Omega(\log n)$$

- Notację theta $\theta(n)$ //ograniczenie z dwóch stron

– Definicja

$$\Theta(g(n)) = \{f(n) \mid \exists c_1, c_2 > 0, \exists n_0 \in \mathbb{N}, \forall n \geq n_0, 0 \leq c_1 \cdot g(n) \leq f(n) \leq c_2 \cdot g(n)\}$$

– Przykład

$$* n^3 = \Theta(n^3)$$

$$* n^3 = \Theta(n^3 + 2n^2)$$

$$* \log n + 8 + \frac{1}{12n} = \Theta(\log n)$$

– Uwaga!

$$f(n) = \Theta(g(n)) \iff f(n) = O(g(n)) \wedge f(n) = \Omega(g(n))$$

Można to zapisać jako klasy funkcji:

$$\Theta(g(n)) = O(g(n)) \cap \Omega(g(n))$$

- Patologiczny przykład: mamy funkcje $g(n) = n$ oraz $f(n) = n^{1+\sin \frac{\pi n}{2}}$, a więc

$$f(n) = \begin{cases} n^2 & \text{dla } n \text{ parzystych} \\ n & \text{dla } n \text{ nieparzystych} \end{cases}$$

wtedy

$$\limsup_{n \rightarrow \infty} \frac{f(n)}{g(n)} = \infty$$

$$\limsup_{n \rightarrow \infty} \frac{g(n)}{f(n)} = \infty$$

zatem $f \neq O(g)$ oraz $g \neq O(f)$

- o małe

– Definicja

$$o(g(n)) = \{f(n) \mid \forall c > 0, \exists n_0 \in \mathbb{N}, \forall n \geq n_0, 0 \leq f(n) < c \cdot g(n)\}$$

Równoważnie

$$\lim_{n \rightarrow \infty} \frac{f(n)}{g(n)} = 0$$

– Przykład

$$* n^2 = o(n^3) \text{ i } n^2 O(n^3) \text{ ale } n^2 \neq o(n^2)$$

$$* n = o(n^2)$$

3.2 Rekurencja

- Metoda podstawienia (metoda dowodu indukcyjnego)

1. Zadnij Odpowiedź (bez stałych)
2. Sprawdź przez indukcję czy odpowiedź jest poprawna
3. Wylicz stałe

– Przykład

* $T(n) = T(\frac{n}{2}) + n$

* Pierwotny strzał: $T(n) = O(n^3)$

* cel: Pokazać, że $\exists c > 0 : T(n) \leq c \cdot n^3$

· warunek początkowy: $T(1) = 1 \leq c$

· krok indukcyjny: założmy, że $\forall k \leq n : T(k) \leq ck^3$

$$T(n) = 4T(\frac{n}{2}) + n \leq 4c(\frac{n}{2})^3 + n = \frac{1}{2}cn^3 + n \leq cn^3 \quad \text{dla } c \geq 2$$

jednakże “Przestrzeliliśmy” znacznie, spróbujmy wzmocnić założenie indukcyjne:

$$T(n) \leq c_1 k^2 - c_2 k, k < n$$

wtedy mamy:

$$T(n) = 4T(\frac{n}{2}) + n \leq 4(c_1(\frac{n}{2})^2 - c_2(\frac{n}{2})) + n = c_1 n^2 - 2c_2 n + n \leq c_1 n^2 - c_2 n$$

zatem $c_1 = 1, c_2 = 1$ i $T(n) = O(n^2)$ □

– Przykład

* $T(n) = 2T(\sqrt{n}) + \log n$

założmy, że n jest potęgą liczby 2, czyli $n = 2^m$

$$T(2^m) = 2T(2^{\frac{m}{2}}) + m$$

Co implikuje

$$T(2^{\frac{m}{2}}) \rightarrow S(m)$$

wtedy

$$S(m) = 2S(\frac{m}{2}) + m$$

rozwiązując rekurencję otrzymujemy

$$S(m) = m \log m$$

zatem


$$T(n) = \log n \log \log n$$

4 Wykład 2025-03-17

4.1 Drzewo rekursji

Przykład dzewa rekursji:

- $T(n) = T(\frac{n}{2}) + T(\frac{n}{4}) + n^2$



Uwaga!

Nie jest to formalne rozwiązanie problemu. Nie można używać drzewa rekursji do dowodzenia złożoności algorytmów. Jest to jedynie intuicyjne podejście do problemu. Trzeba policzyć to na piechotę, aby było formalnie.

Aby policzyć $T(n)$ musimy policzyć sumę wszystkich wierzchołków w drzewie rekursji.

$$T(n) = \sum_{k=0}^{\infty} \left(\frac{5}{16}\right)^k \cdot n^2 = n^2 \sum_{k=0}^{\infty} \left(\frac{5}{16}\right)^k = n^2 \frac{1}{1 - \frac{5}{16}} = n^2 \frac{16}{11} = \frac{16}{11} n^2$$

A więc $T(n) = O(n^2)$

Możemy to policzyć dokładniej dostając mniejsze wyrazy w sumie.

$$T(n) = O(\hat{T}(n)) = O(\check{T}(n))$$

$$T(n) = \Omega(\check{T}(n))$$

$$T(n) = \Theta(n^2) = \frac{16}{11} n^2 + o(n^2)$$

4.2 Metoda iteracyjna

Weźmy na przykład taką rekurencję:

$$T(n) = 3T\left(\frac{n}{4}\right) + n$$

Zobaczmy co się dzieje po podstawieniu rekurencji do samej siebie:

1. $T(n) = 3T\left(\frac{n}{4}\right) + n$
2. $T(n) = 3\left(3T\left(\frac{n}{16}\right) + \frac{n}{4}\right) + n = 3^2 T\left(\frac{n}{16}\right) + \frac{3}{4}n + n$
3. $T(n) = 3^2\left(3T\left(\frac{n}{64}\right) + \frac{n}{16}\right) + \frac{3}{4}n + n = 3^3 T\left(\frac{n}{64}\right) + \frac{3}{16}n + \frac{3}{4}n + n$
4. ...¹

A więc ogólnie wychodzi:

4.3 Master Theorem

Niech $a \geq 1, b > 1, f(n), d \in \mathbb{N}$ oraz $f(n)$ będzie funkcją nieujemną. Rozważmy rekurencję:

$$T(n) = aT\left(\frac{n}{b}\right) + \Theta(n^d)$$

gdzie a i b są stałymi, a $f(n)$ jest funkcją nieujemną. Wtedy:


1. $\Theta(n^d)$ jeśli $d > \log_b a$
2. $\Theta(n^d \log n)$ jeśli $d = \log_b a$
3. $\Theta(n^{\log_b a})$ jeśli $d < \log_b a$

¹Warto zauważyć, że jest to analogicznie do liczenia sumy wszystkich nodów drzewa rekursji

Szkic D-d

Do przedstawienia problemu użyjemy drzewa rekursji. Rozważmy rekurencję:

$$T(n) = aT\left(\frac{n}{b}\right) + \Theta(n^d)$$



1. suma kosztów w k -tym kroku

$$a^k c \left(\frac{n}{b^k}\right)^d = c \left(\frac{a}{b^d}\right)^k n^d$$

gdzie $c \left(\frac{n}{b^k}\right)^d$ to koszt jednego podproblemu w k -tym kroku

2. obliczenie wysokości drzewa:

$$\frac{n}{b^h} = 1 \rightarrow h = \log_b n$$

3. Obliczenie $T(n)$

$$T(n) = \Theta\left(\sum_{k=0}^{\log_b n} c \frac{a}{b^k} n^d\right) = \Theta\left(c \cdot n^d \sum_{k=0}^{\log_b n} \left(\frac{a}{b^d}\right)^k\right) = \Theta\left(c \cdot n^d \frac{1 - \left(\frac{a}{b^d}\right)^{\log_b n + 1}}{1 - \frac{a}{b^d}}\right) \Rightarrow T(n) = \Theta(n^d)$$

4. rozważmy 3 przypadki:

(a) $d > \log_b a$

$$T(n) = \Theta(n^d)$$

root – he
avy

(b) $d = \log_b a$

$$T(n) = \Theta(n^d \log n)$$

równy

(c) $d < \log_b a$

$$T(n) = \Theta(n^{\log_b a})$$

leaf – he
avy

Przykłady

- $T(n) = 4T\left(\frac{n}{2}\right) + 11n$

Wtedy korzystając z **Master Theorem** mamy:

$$a = 4, b = 2, d = 1$$

Jak i również

$$\log_b a = \log_2 4 = 2 > 1 = d \Rightarrow T(n) = \Theta(n^2)$$

- $T(n) = 4T(\frac{n}{3}) + 3n^2$

Wtedy

$$a = 4, b = 3, d = 2$$

Jak i również

$$\log_b a = \log_3 4 > 2 = d \implies T(n) = \Theta(n^{\log_3 4})$$

- $T(n) = 27T(\frac{n}{3}) + \frac{n^2}{3}$

Wtedy

$$a = 27, b = 3, d = 2$$

Jak i również

$$\log_b a = \log_3 27 = 3 > 2 = d \implies T(n) = \Theta(n^3 \log n)$$

4.4 Metoda dziel i zwyciężaj (D&C)

Na czym ona polega?

1. Podział problemu na mniejsze podproblemy ²
2. Rozwiązanie rekurencyjnie mniejsze podproblemy
3. połącz rozwiązania podproblemów w celu rozwiązania problemu wejściowego

4.4.1 Algorytm – Binary Search

- **Input:** posortowana tablica $A[1..n]$ oraz element x
- **Output:** indeks i taki, że $A[i] = x$ lub 0 jeśli x nie występuje w A
- przebieg algorytmu:

Algorithm 3 Binary Search

```

1: procedure BINARYSEARCH( $A, x$ )
2:    $l = 1$ 
3:    $r = |A|$ 
4:   while  $l \leq r$  do
5:      $m = \lfloor \frac{l+r}{2} \rfloor$ 
6:     if  $A[m] = x$  then
7:       return  $m$ 
8:     else if  $A[m] < x$  then
9:        $l = m + 1$ 
10:    else
11:       $r = m - 1$ 
12:    end if
13:  end while
14:  return 0
15: end procedure

```

- **Asymptotyka** Algorytm spełnia następującą rekurencję:

$$T(n) = T(\frac{n}{2}) + \Theta(1)$$

Rozwiązując za pomocą **Master Theorem** otrzymujemy:

$$T(n) = \Theta(\log n)$$

²W zapisie rekurencyjnym $T(n) = cT(\frac{n}{b}) + \underline{n^d}$

4.4.2 Algorytm – potęgowanie liczby do naturalnej potęgi

- **Problem:** obliczanie x^n

Można rozbić mnożenie n x na odpowiednie podproblemy:

$$x^n = \underbrace{x \cdot x \cdot \dots \cdot x}_{\frac{n}{2}} \cdot \underbrace{x \cdot x \cdot \dots \cdot x}_{\frac{n}{2}}$$

A więc mamy:

$$x^n = \begin{cases} x^{\frac{n}{2}} \cdot x^{\frac{n}{2}} & \text{dla } n \text{ parzystych} \\ x^{\frac{n-1}{2}} \cdot x^{\frac{n-1}{2}} \cdot x & \text{dla } n \text{ nieparzystych} \end{cases}$$

- **Asymptotyka:**

Algorytm spełnia następującą rekurencję:

$$T(n) = T\left(\frac{n}{2}\right) + \Theta(1)$$

Rozwiązując za pomocą **Master Theorem** otrzymujemy:

$$T(n) = \Theta(\log n)$$

4.4.3 Obliczenie n-tej liczby Fibonacciego


- **Problem:**

$$F_n = \begin{cases} 0 & \text{dla } n = 0 \\ 1 & \text{dla } n = 1 \\ F_{n-1} + F_{n-2} & \text{dla } n > 1 \end{cases}$$

- **Algorytmy:**

1. Naiwna rekurencja używająca definicji.

Obliczanie F_4



Kontynuując dostajemy asymptotyke rzędu $\Theta(\phi^n)$

2. *bottom up* – iteracyjne obliczanie kolejnych liczb Fibonacciego. Asymptotyka wynosi $\Theta(n)$
3. Kożystanie z wzoru wynikającego z rozwiązanej rekurencji:

$$F_n = \frac{1}{\sqrt{5}} \left(\left(\frac{1 + \sqrt{5}}{2} \right)^n - \left(\frac{1 - \sqrt{5}}{2} \right)^n \right)$$

Problem z tym podejściem polega na niedokładnym przybliżeniu przez komputery wartości ϕ

4. Kożystając z lematu:

$$\begin{pmatrix} 1 & 1 \\ 1 & 0 \end{pmatrix}^n = \begin{pmatrix} F_{n+1} & F_n \\ F_n & F_{n-1} \end{pmatrix},$$

Dowód. (a) Warunek początkowy: dla $n = 0$

$$\begin{pmatrix} 1 & 1 \\ 1 & 0 \end{pmatrix}^0 = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} F_1 & F_0 \\ F_0 & F_{-1} \end{pmatrix}$$

(b) Krok indukcyjny:

załóży, że dla pewnego k zachodzi:

$$\begin{pmatrix} 1 & 1 \\ 1 & 0 \end{pmatrix}^k = \begin{pmatrix} F_{k+1} & F_k \\ F_k & F_{k-1} \end{pmatrix}$$

wtedy dla $k + 1$ mamy:

$$\begin{aligned} \begin{pmatrix} 1 & 1 \\ 1 & 0 \end{pmatrix}^{k+1} &= \begin{pmatrix} 1 & 1 \\ 1 & 0 \end{pmatrix}^k \begin{pmatrix} 1 & 1 \\ 1 & 0 \end{pmatrix} = \begin{pmatrix} F_{k+1} & F_k \\ F_k & F_{k-1} \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 1 & 0 \end{pmatrix} = \begin{pmatrix} F_{k+1} + F_k & F_{k+1} \\ F_k + F_{k-1} & F_k \end{pmatrix} = \begin{pmatrix} F_{k+2} & F_{k+1} \\ F_{k+1} & F_k \end{pmatrix} \end{aligned}$$

□

Algorytm ten ma złożoność $\Theta(n \log n)$

4.4.4 Mnożenie liczb

- **Input:** x, y takie, że $\max\{|x|, |y|\}$

- **Output:** $x \cdot y$

- **Algorytmy:**

1. standardowe mnożenie szkolne – mnożenia w słupku jego asyptotyka wynosi $\Theta(n^2)$

2. Podejście metodą **D&C**

- **Podejście:** Rozbijamy liczby na dwie równe części, a następnie mnożymy je przez siebie
Możemy zapisać x oraz y jako:

$$x = \underbrace{x_L \cdot 2^{\frac{n}{2}}}_{\frac{n}{2} \text{ bitów}} + \underbrace{x_R}_{\frac{n}{2} \text{ bitów}}$$

$$y = \underbrace{y_L \cdot 2^{\frac{n}{2}}}_{\frac{n}{2} \text{ bitów}} + \underbrace{y_R}_{\frac{n}{2} \text{ bitów}}$$

Proces mnożenia wygląda następująco:

$$\begin{aligned} x \cdot y &= (x_L \cdot 2^n + x_R) \cdot (y_L \cdot 2^n + y_R) \\ &= x_L y_L \cdot 2^{2n} + ((x_L + x_R)(y_L + y_R) - x_L y_L - x_R y_R) \cdot 2^n \\ &\quad + x_R y_R \end{aligned}$$

Generalnie wszystkie wykonywane powyżej operacje są giga tanie bo operacje takie jak mnożenie przez 2^k wiąże się jedynie z przesunięciem bitowym.

- **Asymptotyka:** Nasz algorytm spełnia następującą rekurencję na podstawie zapisanego wyżej równania

$$T(n) = 4T\left(\frac{n}{2}\right) + \Theta(n)$$

Kożystając ponownie z **Master Theorem** można wywnioskować, że algorytm ma złożoność $\Theta(n^2)$. Zatem nie ma żadnego znacznego przyspieszenia, nawet prawdopodobnie stała ukryta w $\Theta(n^2)$ jest gorsza niż w standardowym podjeściu

3. Metoda Gaussa

- Rozważmy mnożenie liczb zespolonych

$$(a + ib)(c + id) = ac + i(ad + bc) + bd$$

$$bc + ad = (a + b)(c + d) - ac - bd$$

zatem

$$x \cdot y = x_L y_L \cdot 2^n + ((x_L + x_R)(y_L + y_R) - x_L y_L - x_R y_R) \cdot 2^{\frac{n}{2}} + x_R y_R$$

- **Asymptotyka:** algorytm ten spełnia rekurencję

$$T(n) = 3T\left(\frac{n}{2}\right) + \Theta(n)$$

Z **Master Theorem** otrzymujemy, że algorytm ma złożoność $\Theta(n^{\log_2 3})$, a $\log_2 3 \approx 1.58$

4. Istnieją jeszcze szybsze, nowsze algorytmy mnożenia liczb, takie jak algorytm Schönhage’a-Strassena bazuje ono na szybkiej transformacie Fouriera *Fast Fourier Transform*, który ma złożoność $\Theta(n \log n \log \log n)$. Jednakże, trzeba wziąć pod uwagę stałą ukrytą w Θ . W praktyce, dla liczb o rozmiarze do 10^6 lepiej jest użyć standardowego algorytmu mnożenia.

Trochę pseudo kodu dla mnożenia liczb:

Algorithm 4 Mnożenie liczb

```
1: procedure MULTIPLY( $x, y$ )
2:    $n = \max\{|x|, |y|\}$ 
3:   if  $n = 1$  then
4:     return  $x \cdot y$ 
5:   end if
6:    $x_L, x_R = \text{LeftMost} \left\lceil \frac{n}{2} \right\rceil, \text{RightMost} \left\lceil \frac{n}{2} \right\rceil$  bits of  $x$ 
7:    $y_L, y_R = \text{LeftMost} \left\lceil \frac{n}{2} \right\rceil, \text{RightMost} \left\lceil \frac{n}{2} \right\rceil$  bits of  $y$ 
8:    $p_1 = \text{Multiply}(x_L, y_L)$ 
9:    $p_2 = \text{Multiply}(x_R, y_R)$ 
10:   $p_3 = \text{Multiply}(x_L + x_R, y_L + y_R)$ 
11:  return  $p_1 \cdot 2^{2n} + (p_3 - p_1 - p_2) \cdot 2^n + p_2$ 
12: end procedure
```

4.4.5 Mnożenie macierzy

- **Input:** dwie macierze A, B rozmiaru $n \times n$
- **Output:** macierz $C = A \cdot B$
- **Algorytmy:**

1. Naiwne mnożenie macierzy – jego złożoność wynosi $\Theta(n^3)$ bo aby policzyć jedną komórkę macierzy C musimy wykonać n mnożeń (i $n - 1$ dodawań³), a skoro macierz C ma n^2 komórek to złożoność wynosi $\Theta(n^3)$
2. Algorytm Strassena – **D&C**
 - **Podejście:** Rozbijamy macierze na 4 równe części

$$A = \begin{pmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{pmatrix}$$

³w sumie n^2 operacji

$$B = \begin{pmatrix} B_{11} & B_{12} \\ B_{21} & B_{22} \end{pmatrix}$$

$$C = \begin{pmatrix} C_{11} & C_{12} \\ C_{21} & C_{22} \end{pmatrix}$$

gdzie

$$C_{11} = A_{11}B_{11} + A_{12}B_{21}$$

$$C_{12} = A_{11}B_{12} + A_{12}B_{22}$$

$$C_{21} = A_{21}B_{11} + A_{22}B_{21}$$

$$C_{22} = A_{21}B_{12} + A_{22}B_{22}$$

– **Asymptotyka:** Algorytm ten spełnia rekurencje

$$T(n) = 7T\left(\frac{n}{2}\right) + \Theta(n^2)$$

Z **Master Theorem** otrzymujemy, że algorytm ma złożoność $\Theta(n^{\log_2 7})$, a $\log_2 7 \approx 2.81$
4

4.4.6 Quick Sort

Algorytm **Merge Sort** ociera się o minimalną granicę złożoności sortowania, która wynosi $\Theta(n \log n)$, jednakże jest z nim problem związany z pamięcią: nie sortuje w miejscu, a więc wymaga dodatkowej pamięci.

- **Input:** tablica $A[1..n]$
- **Output:** posortowana tablica A
- **Algorytm:** $\text{QuickSort}(A, p, q)$
 1. Podziel tablicę $A[p..q]$ na dwie podtablice $A[p..k-1]$ oraz $A[k+1..q]$, gdzie $A[k]$ jest elementem rozdzielającym – *pivotem*⁵ tak, że:

$$\forall i \in [p..k-1] : A[i] \leq A[k] : \forall j \in [k+1..q] : A[j] \geq A[k]$$

2. Odpalamy rekurencyjnie $\text{QuickSort}(A, p, k-1)$ oraz $\text{QuickSort}(A, k+1, q)$

- **Przykład:**

1. mamy dane $A = [6, 1, 4, 3, 5, 7, 2, 8]$, wybieramy *pivot* jako 6
2. Przebieg partycjonowania:

$$A = [1, 4, 3, 5, 2, 6, 7, 8]$$

Elementy mniejsze niż 6 znalazły się po lewej stronie, większe po prawej. Pozycja pivota: $A[6] = 6$.

3. Rekurencyjnie sortujemy dwie części:

– $\text{QuickSort}(A, 1, 5)$ dla tablicy $[1, 4, 3, 5, 2]$, np. wybieramy pivot 1:

$$A = [1, 4, 3, 5, 2]$$

Po dalszym sortowaniu otrzymamy $[1, 2, 3, 4, 5]$

– $\text{QuickSort}(A, 7, 8)$ dla $[7, 8]$, który już jest posortowany.


⁴Aby zejść do rekurencji $T(n) = 7T(\frac{n}{2}) + \Theta(n^2)$ trzeba wykonać pewne, bardziej wyrafinowane triki, które nie są dokładnie opisane tutaj. Z algorytmu zapisanego wyżej wynika że rekurencja to $T(n) = 8T(\frac{n}{2}) + \Theta(n^2)$, a więc złożoność wynosi $\Theta(n^3)$

⁵o tym jak ten pivot jest wybierany będziemy mówić później

4. Finalna posortowana tablica:

$$A = [1, 2, 3, 4, 5, 6, 7, 8]$$

Na koniec przykład w drzewie rekursji:



5 Ćwiczenia

tu będą pojawiały się notatki z ćwiczeń do przedmiotu Algorytmy i struktury danych na Politechnice Wrocławskiej na kierunku Informatyka Algorytmiczna rok 2025 semestr letni.

5.1 Lista 2

robiona na zajęciach 2025-03-10

5.1.1 zadanie 1

Wylicz ile linii wypisze poniższy program (podaj wynik będący funkcją od n w postaci asymptotycznej $\Theta(\cdot)$). Można założyć, że n jest potęgą liczby 3. w pseudo kodzie pojawia się następująca

```
1: function f(n)
2: if  $n > 1$  then
3:   print_line('still going')
4:   f(n/3)
5:   f(n/3)
6: end if
```

rekurencja:

$$T(n) = 2T\left(\frac{n}{3}\right) + 1$$

rozwiąże ją używając metody podstawienia. Niech $n = 3^k, k = \log_3 n$, wtedy:

$$T(3^k) = 2T(3^{k-1}) + 1$$

Zatem przyjmując $S(k) = T(3^k)$ mamy:

$$S(k) = 2S(k-1) + 1$$

rozwiązując rekurencję otrzymujemy:

$$S(k) = 2^k - 1$$

zatem

$$T(n) = 2^{\log_3 n} - 1 = n^{\log_3 2} - 1 = \Theta(n^{\log_3 2})$$

analogicznie liczymy jaka jest wykonana “praca” wykonana przez program w drzewie rekursji.

5.1.2 zadanie 2

Niech $f(n)$ i $g(n)$ będą funkcjami asymptotycznie nieujemnymi (tzn. nieujemnymi dla dostatecznie dużego n). Korzystając z definicji notacji Θ , udowodnij, że:

$$\max\{f(n), g(n)\} = \Theta(f(n) + g(n)).$$

Dowód. Z definicji notacji Θ mamy:

$$f(n) = \Theta(g(n)) \iff \exists c_1, c_2 > 0, \exists n_0 \in \mathbb{N}, \forall n \geq n_0, 0 \leq c_1 \cdot g(n) \leq f(n) \leq c_2 \cdot g(n)$$

skoro $f(n)$ i $g(n)$ są asymptotycznie nieujemne to:

$$\exists n_f : \forall n \geq n_f, f(n) \geq 0$$

$$\exists n_g : \forall n \geq n_g, g(n) \geq 0$$

zatem

$$n_0 = \max\{n_f, n_g\}$$

a więc

$$f(n) \leq \max\{f(n), g(n)\}$$

$$g(n) \leq \max\{f(n), g(n)\}$$

dodając obie nierówności otrzymujemy:

$$f(n) + g(n) \leq 2 \cdot \max\{f(n), g(n)\}$$

zatem

$$\forall n \geq n_0 : \max\{f(n), g(n)\} \leq f(n) + g(n) \leq 2 \cdot \max\{f(n), g(n)\}$$

a więc z definicji mamy

$$\max\{f(n), g(n)\} = \Theta(f(n) + g(n))$$

□

5.1.3 zadanie 3

Wylicz asymptotyczną złożoność (używając notacji Θ) poniższych fragmentów programów:

Gdzie:

- koszt wykonania procedury $P(i, j)$ wynosi $\Theta(1)$,
- koszt wykonania procedury $R(i, j)$ wynosi $\Theta(j)$.

Dowód. • Pierwszy fragment kodu

- Wewnętrzna pętla wykonuje się $n - i$ razy
- Koszt wykonania procedury $P(i, j)$ wynosi $\Theta(1)$

Algorithm 5 Pierwszy fragment kodu

```
1: for  $i = 1$  to  $n$  do  
2:    $j = i$   
3:   while  $j < n$  do  
4:      $sum = P(i, j)$   
5:      $j = j + 1$   
6:   end while  
7: end for
```

Algorithm 6 Drugi fragment kodu

```
1: for  $i = 1$  to  $n$  do  
2:    $j = i$   
3:   while  $j < n$  do  
4:      $sum = R(i, j)$   
5:      $j = j + j$   
6:   end while  
7: end for
```

- Zatem koszt wykonania wewnętrznej pętli wynosi $\Theta(n - i)$
- Zatem koszt wykonania całego fragmentu wynosi

$$\sum_{i=1}^n \Theta(n - i) = \Theta(n^2)$$

- Drugi fragment kodu

- Wewnętrzna pętla wykonuje się $\log_2 n$ razy
- Koszt wykonania procedury $R(i, j)$ wynosi $\Theta(j)$
- Zatem koszt wykonania wewnętrznej pętli wynosi $\Theta(\log_2 n)$
- Zatem koszt wykonania całego fragmentu wynosi

$$\sum_{i=1}^n \Theta(\log_2 n) = \Theta(n \log_2 n)$$

□

Dla pewności sprawdzone empirycznie:



5.1.4 zadanie 4

Wyznacz asymptotyczne oszacowanie górne dla następujących rekurencji:

- $T(n) = 2T(n/2) + 1$
- $T(n) = 2T(n/2) + n$
- $T(n) = 3T(n/2) + n \log n$

Kożystając z **Master Theorem** możemy wyznaczyć ograniczenie dla tych rekurencji.

- $T(n) = 2T(n/2) + 1$

Dowód.

$$\begin{aligned} a &= 2, b = 2, d = 0 \\ \log_b a &= \log_2 2 = 1 > 0 = d \\ T(n) &= \Theta(n) \end{aligned}$$

□

- $T(n) = 2T(n/2) + n$

Dowód.

$$\begin{aligned} a &= 2, b = 2, d = 1 \\ \log_b a &= \log_2 2 = 1 = d \\ T(n) &= \Theta(n \log n) \end{aligned}$$

□

- $T(n) = 3T(n/2) + n \log n$

Dowód. Dolne ograniczenie

$$T(n) = 3T(n/2) + n \implies \text{Master Theorem } T(n) = \Theta(n^{\log_2 3})$$

Górne ograniczenie

$$T(n) = 3T(n/2) + n^{1.1} \implies \text{Master Theorem } T(n) = \Theta(n^{1.1})$$

□

5.1.5 zadanie 5

Zaprojektuj algorytm wczytujący z wejścia tablicę liczb $A[1], \dots, A[N]$ i przygotowujący tablicę B tak, że na jej podstawie będzie potrafił odpowiadać na pytania:

1. ile wynosi suma elementów tablicy A od miejsca i do miejsca j włącznie, dla $i < j$.
2. Jaka jest złożoność czasowa Twojego algorytmu? Ile pamięci zajmuje tablica B ?
3. Ile zajmuje odpowiedź na jedno pytanie?

Przykładowy algorytm mógłby wyglądać następująco:

Co tu się dzieje?

- W pierwszej pętli obliczamy sumy prefiksowe tablicy A i zapisujemy je w tablicy B .
- W procedurze `Sum` zwracamy różnicę między dwoma elementami tablicy B .
- Złożoność czasowa algorytmu wynosi $\Theta(n)$.
- Tablica B zajmuje $\Theta(n)$ pamięci.
- Odpowiedź na jedno pytanie zajmuje $\Theta(1)$ czasu.

Algorithm 7 Algorytm do zadania 5.

```
1:  $B[1] = A[1]$ 
2: for  $i = 2$  to  $N$  do
3:    $B[i] = B[i - 1] + A[i]$ 
4: end for
5: procedure SUM( $i, j$ )
6:   return  $B[j] - B[i - 1]$ 
7: end procedure
```

5.1.6 zadanie 6

Pokaż, jak grać w grę w "10 pytań", w której wiadomo, że wybrana liczba jest dodatnia, ale nie jest na początku znane górne ograniczenie jej wartości. Ile pytań potrzebujesz, żeby zgadnąć dowolną liczbę (liczba pytań może zależeć od wielkości liczby)?

W grze "10 pytań" możemy zadać pytania w stylu "czy liczba jest większa od x ". W ten sposób możemy zredukować przestrzeń poszukiwań. W pierwszym pytaniu zapytajmy, czy liczba jest większa od 1. Jeśli tak, to zapytajmy, czy liczba jest większa od 2. W ten sposób możemy zredukować przestrzeń poszukiwań do 2^k dla pewnego k . W ten sposób możemy znaleźć dowolną liczbę w k pytaniach.

5.1.7 zadanie 7

Używając algorytmu **divide-and-conquer** do mnożenia liczb wykonaj mnożenie dwóch liczb binarnych 11011, 1010.

Algorytm **divide-and-conquer** do mnożenia liczb działa w następujący sposób:

1. Podziel liczby na dwie równe części.
2. Rekurencyjnie pomnóż te części.
3. Połącz wyniki.

Mnożenie dwóch liczb binarnych 11011 i 1010 możemy zrealizować w następujący sposób:

1. Podziel liczby na dwie równe części: 1101, 1 oraz 10, 10.
2. Rekurencyjnie pomnóż te części: $1101 \cdot 10 = 11010$.
3. Połącz wyniki: $11010 + 110100 = 1000000$.